

Physics-Informed Neural Networks i les Seves Aplicacions

Treball de Fi de Grau

Lluís Panal Majó

Grau en Matemàtica Computacional i Analítica de Dades
Universitat Autònoma de Barcelona

Juny 2026

Supervisat per Sílvia Cuadrado Gavilán i Alejandra Cabaña Nigro

- 1 Motivació i objectius
- 2 Fonamentació teòrica
- 3 Validació amb equacions clàssiques
- 4 Inestabilitat de Turing
- 5 Model de Meinhardt
- 6 Conclusions

Motivació:

- Unir **equacions diferencials** i **Deep Learning**.
- Fer que una xarxa neuronal aprengui la dinàmica d'un sistema **sense dades reals**, guiant-se només per l'equació.

Objectius:

- 1 Comprendre la fonamentació teòrica de les PINNs.
- 2 Comparar amb mètodes numèrics tradicionals.
- 3 Validar amb equacions clàssiques (logística, Burgers, Fisher).
- 4 Aplicar-les a la **inestabilitat de Turing** (model de Meinhardt): problema directe i invers.

Una **xarxa neuronal** aproxima funcions composant operacions lineals i no lineals en capes successives.

Cada neurona calcula:

$$z = W^T x + b \quad (\text{combinació lineal}), \quad (1)$$

$$a = \sigma(z) \quad (\text{activació no lineal, p. ex. tanh}). \quad (2)$$

Entrenament: es minimitza una funció de pèrdua (MSE) amb el descens del gradient:

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N |u_{\theta}(x_i) - y_i|^2, \quad \theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$$

Diferenciació automàtica

Per calcular $\nabla_{\theta} \mathcal{L}$ s'utilitza la **retropropagació**: es recorre el graf computacional en sentit invers aplicant la regla de la cadena.

$$\frac{\partial \mathcal{L}}{\partial W_i} = \frac{\partial \mathcal{L}}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial W_i}$$

Un sol recorregut $\Rightarrow$ **totes** les derivades de forma exacta.

Què és una PINN?

Idea central

Una xarxa neuronal que incorpora l'equació diferencial dins la seva **funció de pèrdua**.

Segui l'equació diferencial $\mathcal{N}[u(x, t)] = 0$. La PINN $u_\theta(x, t)$ s'entrena minimitzant:

$$\mathcal{L}(\theta) = \underbrace{\frac{1}{N_u} \sum_{i=1}^{N_u} |u_\theta(x_i, t_i) - u_i|^2}_{\mathcal{L}_{data}: \text{Condicions inicials i de contorn}} + \underbrace{\frac{1}{N_f} \sum_{j=1}^{N_f} |\mathcal{N}[u_\theta(x_j, t_j)]|^2}_{\mathcal{L}_{física}: \text{Residu de l'EDP en punts arbitraris}}$$

- Si la xarxa **trenca la física**, $\mathcal{N}[u_\theta] \neq 0 \Rightarrow$ penalització $\Rightarrow$ ajusta els pesos.
- **Doble ús de l'AD:** (1) optimitzar θ com sempre, i (2) calcular $\frac{\partial u_\theta}{\partial t}$, $\frac{\partial^2 u_\theta}{\partial x^2}$, ... de forma **exacta**, sense malla.

Avantatges de les PINNs

- **Sense malla** (*mesh-free*): escala millor en altes dimensions.
- **Problemes inversos**: descobrir paràmetres a partir de dades.
- **Avaluació ràpida**.
- **Transfer Learning**.

Inconvenients de les PINNs

- **Entrenament lent**.
- **Mínims locals**: sense garanties de convergència.
- **F-Principle**: dificultat amb canvis bruscos i altes freqüències.
- **Cerca d'hiperparàmetres**.

Equació Logística

$$\frac{du}{dt} = u(1 - u), \quad u(0) = 0.1, \quad t \in [0, 10].$$

Solució exacta: $u(t) = \frac{1}{1 + 9e^{-t}}$

Equilibris:

- $u_1^* = 0$: inestable (repulsor).
- $u_2^* = 1$: estable (atractor).

Problema: mínim local

La xarxa prediu $u = 0$ a tot el domini. Com que $\mathcal{N}[0] = 0$, el residu s'anul·la i l'optimitzador s'hi queda atrapat.




Figura: El model respecta la CI, però decau a l'equilibri inestable $u = 0$.

Solució: imposar la CI per construcció

Redefinir la sortida de la xarxa:

$$u_{pred}(t) = u_0 + t \cdot u_{\theta}(t)$$

- A $t=0$: $u_{pred} = u_0$ automàticament.
- S'elimina l'error de la CI de la funció de pèrdua.
- La xarxa passa a modelar la *taxa de canvi*, no la població directa.

Amb aquesta modificació, el model convergeix correctament cap a l'equilibri estable $u = 1$.






Figura: La predicció se solapa perfectament amb la solució analítica.

Equació de Burgers i equació de Fisher



Burgers (EDP no viscosa)

$$u_t + u u_x = 0$$



Fisher (reacció-difusió)

$$u_t - u_{xx} - u(1-u) = 0$$



Inestabilitat de Turing

Idea (A. Turing, 1952)

Quan dues substàncies que interactuen es difonen a **velocitats diferents**, la difusió pot trencar un equilibri que era estable i crear **patrons espacials** de forma espontània (*morfogènesi*).

Requisits:

- Amb 1 sola equació, la difusió sempre **estabilitza**.
- Calen ≥ 2 substàncies (u_1, u_2) que interaccionin.
- Coeficients de difusió **diferents**: $d_1 \neq d_2$.
- La diferència de velocitats de propagació és la que trenca la simetria espacial.

Formulació matemàtica:

$$\begin{cases} \frac{\partial u_1}{\partial t} = d_1 \nabla^2 u_1 + f_1(u_1, u_2), \\ \frac{\partial u_2}{\partial t} = d_2 \nabla^2 u_2 + f_2(u_1, u_2). \end{cases}$$

On f_1, f_2 descriuen la **reacció** i $d_i \nabla^2 u_i$ la **difusió**.

Objectiu

Establir quan la difusió desestabilitza un equilibri homogeni $(\hat{u}_1, \hat{u}_2)$ que, d'altra manera, seria estable.

Analitzem pertorbacions $\sim e^{\sigma t} \cos(qx)$. La taxa de creixement σ és valor propi de $J - q^2 D$:

$$J = \begin{pmatrix} f_{1u_1} & f_{1u_2} \\ f_{2u_1} & f_{2u_2} \end{pmatrix} \quad (\text{reacció}), \quad D = \begin{pmatrix} d_1 & 0 \\ 0 & d_2 \end{pmatrix} \quad (\text{difusió})$$

Els patrons emergeixen ($\sigma > 0$ per a algun mode q) si es compleixen **4 condicions**:

Sense difusió (equilibri estable)

- ❶ $\text{Tr}(J) < 0$
- ❷ $\det(J) > 0$

Amb difusió (desestabilització)

- ❸ $f_{1u_1} d_2 + f_{2u_2} d_1 > 0$
- ❹ $(f_{1u_1} d_2 + f_{2u_2} d_1)^2 > 4 d_1 d_2 \det(J)$

Model de Meinhardt

Un cas concret d'inestabilitat de Turing. L'activador (u_1) creix on hi ha concentració alta i l'inhibidor (u_2) s'hi oposa difonent-se molt més ràpid:

$$\begin{cases} \frac{\partial u_1}{\partial t} = \alpha u_1^2 u_2 - \mu u_1 + d_1 \nabla^2 u_1, \\ \frac{\partial u_2}{\partial t} = \beta - \alpha u_1^2 u_2 + d_2 \nabla^2 u_2. \end{cases} \quad (x, y) \in [0, 25]^2$$

$$\text{Equilibri homogeni: } (\hat{u}_1, \hat{u}_2) = \left(\frac{\beta}{\mu}, \frac{\mu^2}{\alpha\beta} \right).$$


Paràmetres: $\alpha=2$, $\beta=1$, $\mu=1$, $d_1=1$,
 $d_2=12$.

Modes d'ona inestables: $\frac{1}{3} < q^2 < \frac{1}{2}$

on $q^2 = \left(\frac{n\pi}{L}\right)^2 + \left(\frac{m\pi}{L}\right)^2$, $n, m \in \mathbb{N}_0$.


CI: pertorbació sobre l'equilibri amb mode
 (n, m) : $u_i(x, y, 0) = \hat{u}_i + 0.1 \cos \frac{n\pi x}{L} \cos \frac{m\pi y}{L}$

Bandes ($n=5, m=0$)



Inestabilitat només en $x \Rightarrow$ ratlles verticals.

Taques ($n=3, m=4$)



Inestabilitat en x i $y \Rightarrow$ *spots*.

Activador i inhibidor generen ones **oposades**: on u_1 és màxim, u_2 és mínim.

Problema invers — Descobrir paràmetres a partir de dades

Experiment	Paràmetre	Valor real	Predicció	MSE solució
Cas 1: Taxes de reacció	α	2.0000	1.9909	$u_1: 1.55 \times 10^{-5}$
	β	1.0000	0.9956	$u_2: 3.19 \times 10^{-6}$
Cas 2: Coef. de difusió	d_1	1.0000	1.0099	$u_1: 1.03 \times 10^{-5}$
	d_2	12.0000	12.0218	$u_2: 4.84 \times 10^{-6}$
Cas 3: Tots els paràmetres	α	2.0000	1.2071	$u_1: 1.30 \times 10^{-4}$
	β	1.0000	0.6024	$u_2: 5.32 \times 10^{-5}$
	μ	1.0000	0.6029	
	d_1	1.0000	0.5849	
	d_2	12.0000	7.0246	

- Les PINNs **resolen correctament** equacions clàssiques (logística, Burgers, Fisher).
- Simulen la **formació de patrons de Turing** (bandes i taques) amb el model de Meinhardt 2D.
- **Limitacions pràctiques:**
 - Entrenament lent i costós.
 - Risc de mínims locals (cas logístic).
- Les PINNs tenen un **gran potencial**, però cal seguir investigant per competir amb els mètodes tradicionals.

Gràcies!

Preguntes?

Lluís Panal Majó
1668072@uab.cat

Codi font: <https://github.com/LlPanal/PINN>